

// Jivops

AWS ELB

Guía completa — 20 lecciones

Fundamentos · Application Load Balancer · NLB y GWLB · Seguridad y operación

Contenido

Módulo 1: Fundamentos

- Lección 01 — Elastic Load Balancing y sus tipos
- Lección 02 — ALB frente a NLB: cuál elegir
- Lección 03 — Listeners, reglas y target groups
- Lección 04 — Subredes, zonas de disponibilidad y cross-zone
- Lección 05 — Grupos de seguridad y red

Módulo 2: Application Load Balancer

- Lección 06 — Reglas de ALB: condiciones y acciones
- Lección 07 — Target groups y health checks
- Lección 08 — Algoritmos, slow start y sesiones persistentes
- Lección 09 — Autenticación y redirecciones en ALB
- Lección 10 — HTTP/2, gRPC, WebSockets y timeouts

Módulo 3: NLB y GWLB

- Lección 11 — Network Load Balancer: características
- Lección 12 — Preservación de la IP del cliente y Proxy Protocol
- Lección 13 — TLS y UDP en NLB
- Lección 14 — Gateway Load Balancer
- Lección 15 — Combinaciones: ALB detrás de NLB y Global Accelerator

Módulo 4: Seguridad y operación

- Lección 16 — TLS, ACM, SNI y políticas de seguridad
- Lección 17 — AWS WAF y Shield
- Lección 18 — Observabilidad: CloudWatch y logs
- Lección 19 — Integración con Auto Scaling y Kubernetes
- Lección 20 — Proyecto final: balanceo listo para producción

Módulo 1: Fundamentos

Lección 01 — Elastic Load Balancing y sus tipos

El servicio gestionado de AWS que reparte tráfico entre destinos en varias zonas de disponibilidad; incluye Application Load Balancer (capa 7), Network Load Balancer (capa 4), Gateway Load Balancer (capa 3, para appliances) y el Classic Load Balancer, que es la generación anterior.

Porque ALB y NLB lo han sustituido con más funciones y mejor rendimiento; AWS recomienda migrar.

Lección 02 — ALB frente a NLB: cuál elegir

ALB para HTTP/HTTPS/gRPC cuando se necesita enrutado por host, ruta o cabeceras y funciones de capa 7; NLB para TCP/UDP/TLS con muy baja latencia, millones de conexiones, IP estática por zona y preservación de la IP del cliente.

Un ALB, porque permite reglas por ruta (/users, /orders) hacia grupos de destino distintos.

Lección 03 — Listeners, reglas y target groups

El listener escucha en un protocolo y puerto, sus reglas (condiciones y acciones, ordenadas por prioridad) deciden qué hacer con cada petición y la acción forward envía el tráfico a un target group, que contiene los destinos y sus health checks.

Se aplica la acción por defecto (default action) del listener.

Lección 04 — Subredes, zonas de disponibilidad y cross-zone

Que cada nodo del balanceador reparte el tráfico entre los destinos de todas las zonas habilitadas y no solo los de su zona; en ALB está siempre activo y en NLB está desactivado por defecto y, si se activa, puede generar costes de transferencia entre zonas.

El tráfico se reparte por igual entre zonas, no entre destinos, así que los destinos de la zona con menos instancias se sobrecargan.

Lección 05 — Grupos de seguridad y red

Un grupo de seguridad en el ALB permite el tráfico de los clientes (por ejemplo 80/443), y el grupo de seguridad de los destinos solo permite el tráfico procedente del grupo del ALB, de modo que los destinos no son accesibles directamente desde internet.

Para que no sean accesibles directamente desde internet y todo el tráfico entre por el balanceador.

Módulo 2: Application Load Balancer

Lección 06 — Reglas de ALB: condiciones y acciones

Combinar condiciones (host, ruta, cabecera, parámetro de consulta, IP de origen, método) y ejecutar acciones como forward (a uno o varios target groups con pesos), redirect o fixed-response, ordenadas por prioridad numérica.

Una acción forward con dos target groups ponderados (por ejemplo 90 y 10).

Lección 07 — Target groups y health checks

El balanceador sondea cada destino con el protocolo, ruta y puerto configurados; un destino pasa a sano o no sano según los umbrales (healthy y unhealthy threshold), y solo recibe tráfico mientras esté sano; los tipos de destino incluyen instancia, IP y Lambda.

Porque la aplicación puede estar levantada pero inutilizable (por ejemplo sin base de datos); aunque conviene no hacerla tan estricta que retire todos los destinos por una dependencia común.

Lección 08 — Algoritmos, slow start y sesiones persistentes

Algoritmos round robin, least outstanding requests y weighted random, slow start para introducir gradualmente destinos nuevos y sesiones persistentes (stickiness) por cookie generada por el balanceador o por la aplicación.

Cuando un destino nuevo necesita calentar (caché fría o carga de la aplicación) y no debe recibir todo el tráfico de golpe.

Lección 09 — Autenticación y redirecciones en ALB

Acciones de autenticación integradas con Amazon Cognito o un proveedor OIDC, que redirigen al usuario a iniciar sesión antes de reenviar la petición, y pasan los datos de identidad al destino en cabeceras; también redirecciones como HTTP a HTTPS.

Se centraliza la autenticación sin añadir código a cada aplicación, y los destinos solo reciben usuarios autenticados.

Lección 10 — HTTP/2, gRPC, WebSockets y timeouts

El ALB admite HTTP/2, gRPC y WebSockets, pero tiene un tiempo de inactividad (idle timeout, 60 segundos por defecto) tras el cual cierra la conexión; para conexiones largas hay que ajustarlo o enviar tráfico periódico.

El idle timeout del ALB (60 s por defecto) y el keep-alive del servidor, aumentando el valor si procede.

Módulo 3: NLB y GWLB

Lección 11 — Network Load Balancer: características

Opera en capa 4 con TCP, UDP y TLS, mantiene latencias muy bajas y soporta millones de conexiones, ofrece una IP estática (o Elastic IP) por zona de disponibilidad, y admite como destinos instancias, IP o un ALB.

Porque ofrece una IP estática (o Elastic IP) por zona, que el cliente puede permitir en su firewall.

Lección 12 — Preservación de la IP del cliente y Proxy Protocol

Con destinos de tipo instancia el NLB conserva la IP de origen del cliente; con destinos de tipo IP puede no hacerlo según la configuración, y Proxy Protocol v2 permite enviar la información de conexión original al destino, que debe estar preparado para leerlo.

El servidor interpretará la cabecera como parte de los datos y las conexiones o peticiones fallarán.

Lección 13 — TLS y UDP en NLB

Un listener TLS termina el cifrado en el NLB con un certificado de ACM y reenvía tráfico claro o cifrado a los destinos, o se usa un listener TCP para pasar el cifrado sin descifrar (passthrough); UDP se balancea por flujo.

Cuando se requiere cifrado de extremo a extremo y el certificado debe estar en el destino, sin que el NLB descifre.

Lección 14 — Gateway Load Balancer

Para desplegar y escalar appliances virtuales de red (firewalls, IDS/IPS, inspección profunda) de forma transparente, usando el protocolo GENEVE para encapsular el tráfico hacia ellos y recibirlo de vuelta; combina un punto de entrada y un balanceador.

Escala automáticamente los appliances, ofrece alta disponibilidad y es transparente para el flujo de tráfico.

Lección 15 — Combinaciones: ALB detrás de NLB y Global Accelerator

Para obtener direcciones IP estáticas (del NLB) y a la vez enrutado de capa 7 (del ALB); AWS Global Accelerator también puede dar IP estáticas anycast y enrutar al borde más cercano antes de llegar al balanceador.

Un NLB con IP estática delante de un ALB que haga el enrutado por ruta, o Global Accelerator con IP estáticas hacia el ALB.

Módulo 4: Seguridad y operación

Lección 16 — TLS, ACM, SNI y políticas de seguridad

Con certificados de AWS Certificate Manager (renovación automática) asociados al listener HTTPS, SNI para servir varios dominios con distintos certificados en un mismo listener y una política de seguridad TLS que fije versiones y cifrados permitidos.

Porque deshabilita versiones y cifrados antiguos e inseguros, quedándose con TLS 1.2 y 1.3.

Lección 17 — AWS WAF y Shield

Asociando una Web ACL de AWS WAF para filtrar peticiones (inyecciones, bots, límites de tasa) y usando AWS Shield contra ataques de denegación de servicio; el NLB no admite WAF directamente.

Una regla basada en tasa (rate-based) que bloquea las IP que superan un número de peticiones.

Lección 18 — Observabilidad: CloudWatch y logs

Con métricas de CloudWatch (peticiones, latencia del destino, errores 4XX/5XX, destinos sanos y no sanos) con alarmas, y con registros de acceso en S3 que detallan cada petición para análisis posterior.

Errores 5XX del destino y destinos no sanos (UnHealthyHostCount), o latencia elevada.

Lección 19 — Integración con Auto Scaling y Kubernetes

Asociando el Auto Scaling Group a los target groups: las instancias nuevas se registran solas y las retiradas se quitan tras el drenaje de conexiones (deregistration delay); en Kubernetes, el AWS Load Balancer Controller crea ALB para Ingress y NLB para Services.

Permite terminar las conexiones en curso antes de retirar el destino, evitando errores en un despliegue.

Lección 20 — Proyecto final: balanceo listo para producción

ALB en subredes públicas de varias zonas con redirección HTTP a HTTPS y certificados ACM, destinos en subredes privadas con grupos de seguridad restringidos, health checks de aplicación, WAF, Auto Scaling, alarmas de CloudWatch, logs en S3 y protección contra borrado.

Varias zonas de disponibilidad, WAF y alarmas de CloudWatch (más HTTPS, health checks y destinos privados).