

// Jivops

GlusterFS

Guía completa — 20 lecciones

Fundamentos · Volúmenes y datos · Resiliencia y recuperación · Acceso y operación

Contenido

Módulo 1: Fundamentos

- Lección 01 — Qué es GlusterFS
- Lección 02 — Trusted storage pool y peers
- Lección 03 — Bricks: preparación del almacenamiento
- Lección 04 — Tipos de volumen
- Lección 05 — Crear, arrancar y montar un volumen

Módulo 2: Volúmenes y datos

- Lección 06 — Volúmenes replicados y arbiter
- Lección 07 — Volúmenes dispersos (erasure coding)
- Lección 08 — Distribución de ficheros (DHT)
- Lección 09 — Ampliar volúmenes: add-brick y rebalance
- Lección 10 — Cuotas y opciones de volumen

Módulo 3: Resiliencia y recuperación

- Lección 11 — Self-heal
- Lección 12 — Split-brain
- Lección 13 — Quórum
- Lección 14 — Snapshots
- Lección 15 — Geo-replication

Módulo 4: Acceso y operación

- Lección 16 — Acceso desde clientes: FUSE, NFS-Ganesha y SMB
- Lección 17 — Seguridad: TLS y control de acceso
- Lección 18 — Rendimiento
- Lección 19 — Monitorización y troubleshooting
- Lección 20 — Proyecto final: GlusterFS listo para producción

Módulo 1: Fundamentos

Lección 01 — Qué es GlusterFS

Un sistema de ficheros distribuido y escalable en el que se agregan directorios de varios servidores (bricks) en volúmenes únicos accesibles por red, sin servidor de metadatos central, y que escala añadiendo servidores y bricks.

Evita un punto único de fallo y cuello de botella: los clientes calculan dónde está cada fichero y el sistema escala añadiendo servidores.

Lección 02 — Trusted storage pool y peers

El conjunto de servidores que confían entre sí y forman el cluster de GlusterFS; se construye ejecutando `gluster peer probe` desde un servidor para añadir a los demás, y el demonio `glusterd` de cada servidor gestiona la configuración.

Resolución de nombres coherente, conectividad de red entre ellos (incluido el puerto de `glusterd`) y `glusterd` en ejecución en todos.

Lección 03 — Bricks: preparación del almacenamiento

Con un disco o volumen lógico dedicado, formateado normalmente con XFS, montado en un directorio propio y usando un subdirectorío del punto de montaje como brick, de modo que no se use accidentalmente el sistema raíz.

Si el disco no llegara a montarse, Gluster escribiría en el disco raíz sin avisar; con un subdirectorío el brick no existe y se evita llenar el sistema.

Lección 04 — Tipos de volumen

Distribuido (reparte ficheros entre bricks sin redundancia), replicado (copias en varios bricks), disperso (erasure coding con redundancia configurable) y combinaciones como distribuido-replicado o distribuido-disperso para escalar con tolerancia a fallos.

No tiene redundancia: si un brick falla, se pierden los ficheros que contenía.

Lección 05 — Crear, arrancar y montar un volumen

Crear el volumen indicando tipo y bricks (`gluster volume create`), arrancarlo (`gluster volume start`), comprobarlo con `gluster volume info/status` y montarlo en los clientes, por ejemplo con el cliente nativo FUSE (`mount -t glusterfs`).

Porque se evita la lógica de Gluster (distribución y replicación), lo que produce inconsistencias y pérdida de datos; se escribe siempre a través del volumen montado.

Módulo 2: Volúmenes y datos

Lección 06 — Volúmenes replicados y arbiter

Porque con dos copias es fácil caer en split-brain tras una partición de red, ya que no hay mayoría para decidir cuál es correcta; replica 3 o un brick arbiter (que guarda solo metadatos) aportan el voto necesario con menos riesgo.

Ahorra capacidad: el arbiter guarda solo metadatos, no una copia completa, y aun así aporta el voto para evitar split-brain.

Lección 07 — Volúmenes dispersos (erasure coding)

Divide cada fichero en fragmentos con códigos de redundancia (erasure coding) repartidos entre los bricks, de modo que tolera la pérdida de tantos bricks como redundancia se configure, usando menos espacio que replicar.

Cuando importa aprovechar capacidad (menos sobrecarga que replicar) y las cargas son sobre todo de ficheros grandes con menos escrituras pequeñas.

Lección 08 — Distribución de ficheros (DHT)

Mediante hash elástico (DHT): el nombre del fichero se convierte en un hash y cada brick tiene asignado un rango de hash en el directorio, de modo que el cliente calcula la ubicación sin consultar un servidor de metadatos.

Que el cliente calcula la ubicación sin consultar nada; renombrar un fichero puede cambiar su ubicación esperada y crear punteros entre bricks.

Lección 09 — Ampliar volúmenes: add-brick y rebalance

Ejecutar un rebalance para redistribuir los ficheros y los rangos de hash entre todos los bricks, ya que sin él los ficheros existentes siguen en los bricks antiguos y los nuevos aportan capacidad sin equilibrar la carga.

Porque mueve muchos datos entre bricks y consume E/S y red, lo que puede afectar al rendimiento de las aplicaciones.

Lección 10 — Cuotas y opciones de volumen

Con gluster volume set se cambian opciones (cachés, rendimiento, autenticación, etc.) y con las cuotas se limita el espacio por directorio; conviene revisar el valor por defecto de cada opción y probar los cambios antes de aplicarlos en producción.

Para limitar el espacio que puede ocupar un directorio y evitar que un equipo o aplicación llene el volumen compartido.

Módulo 3: Resiliencia y recuperación

Lección 11 — Self-heal

Detecta y repara automáticamente las réplicas desactualizadas de ficheros, por ejemplo tras caer un brick, copiando los datos desde una réplica buena; el estado se consulta con `gluster volume heal VOLUMEN info`.

El self-heal sincroniza lo que cambió durante la caída copiando desde las réplicas buenas, hasta que no queden entradas pendientes.

Lección 12 — Split-brain

Una situación en la que dos réplicas de un mismo fichero han divergido de forma incompatible (por ejemplo tras una partición de red) y Gluster no puede decidir cuál es la correcta, por lo que el acceso al fichero puede dar error hasta resolverlo.

Usando replica 3 o arbiter y activando el quórum, para que siempre haya una mayoría que decida la copia válida.

Lección 13 — Quórum

Para evitar escrituras divergentes cuando falla la red o parte de los nodos: el quórum de servidor detiene los bricks si no hay mayoría del pool y el de cliente bloquea escrituras si no hay mayoría de réplicas disponibles.

Más consistencia pero menos disponibilidad: sin mayoría se bloquean las escrituras.

Lección 14 — Snapshots

Los bricks deben estar sobre LVM con aprovisionamiento ligero (thin provisioning) y el volumen debe estar arrancado; el snapshot es una copia coherente en un instante que puede restaurarse o activarse para consulta.

Porque vive en el mismo almacenamiento y se pierde con él; un backup debe estar fuera del pool.

Lección 15 — Geo-replication

Replicación asíncrona maestro-esclavo de un volumen hacia otro, normalmente en otro sitio y por SSH, pensada para recuperación ante desastres; el esclavo puede quedar algo atrasado, por lo que hay un RPO distinto de cero.

Los últimos cambios aún no replicados, porque la replicación es asíncrona y el RPO no es cero.

Módulo 4: Acceso y operación

Lección 16 — Acceso desde clientes: FUSE, NFS-Ganesha y SMB

El cliente nativo FUSE (`mount -t glusterfs`), que conoce la topología y conmuta entre servidores, y la exportación por NFS-Ganesha o SMB (Samba) para clientes que no tienen el cliente nativo.

Conoce la topología y puede reconectar a otro servidor si cae el que se usó para montar, lo que da alta disponibilidad.

Lección 17 — Seguridad: TLS y control de acceso

Cifrando con TLS el tráfico de gestión y de E/S, restringiendo qué clientes pueden montar un volumen con `auth.allow`, limitando el acceso a los puertos de `glusterd` y de los bricks con firewall y usando una red privada para el tráfico de almacenamiento.

Aísla el tráfico de datos de redes públicas, reduce la superficie de ataque y evita que compita con el tráfico de las aplicaciones.

Lección 18 — Rendimiento

La red entre clientes y servidores, el tipo de volumen (la replicación y el erasure coding añaden coste), el tamaño de los ficheros (muchos ficheros pequeños son un punto débil), los discos y las cachés de lectura y escritura configuradas.

El coste de operaciones de metadatos con ficheros pequeños, las opciones de caché y si el tipo de volumen y la red son adecuados.

Lección 19 — Monitorización y troubleshooting

Con `gluster volume status e info`, `gluster peer status`, `gluster volume heal info`, los logs en `/var/log/glusterfs` y las métricas exportadas a Prometheus, comprobando bricks caídos, peers desconectados y entradas pendientes de heal.

`gluster volume status` para ver el brick offline, los logs del brick y `heal info` para ver qué falta por sincronizar.

Lección 20 — Proyecto final: GlusterFS listo para producción

Al menos tres servidores con bricks XFS sobre discos dedicados, volúmenes replica 3 o arbiter (o dispersos), red privada con TLS, `auth.allow`, monitorización con alertas, snapshots y geo-replication o backups externos, y planificación del ciclo de vida del proyecto.

Replica 3 o arbiter para evitar split-brain, backups o geo-replication fuera del pool y monitorización con alertas.