

// Jivops

Google Cloud Load Balancing

Guía completa — 20 lecciones

Fundamentos · Balanceador de aplicaciones · Network LB y backends · Seguridad y operación

Contenido

Módulo 1: Fundamentos

- Lección 01 — Visión y tipos de Cloud Load Balancing
- Lección 02 — Componentes de un balanceador
- Lección 03 — Backends: grupos de instancias y NEG
- Lección 04 — Health checks y firewall
- Lección 05 — Niveles de red e IP anycast

Módulo 2: Application Load Balancer

- Lección 06 — Mapas de URL y enrutado
- Lección 07 — Gestión avanzada del tráfico
- Lección 08 — Modos de balanceo y capacidad
- Lección 09 — Sesiones persistentes, timeouts y drenaje
- Lección 10 — Cloud CDN

Módulo 3: Network LB y backends

- Lección 11 — Network Load Balancers: proxy y passthrough
- Lección 12 — Passthrough y preservación de la IP del cliente
- Lección 13 — Balanceador interno y subred solo proxy
- Lección 14 — NEG: serverless y contenedores en GKE
- Lección 15 — Multirregión, NEG híbridos y conmutación

Módulo 4: Seguridad y operación

- Lección 16 — TLS y certificados gestionados
- Lección 17 — Cloud Armor
- Lección 18 — Identity-Aware Proxy y control de acceso
- Lección 19 — Observabilidad y troubleshooting
- Lección 20 — Proyecto final: balanceo listo para producción

Módulo 1: Fundamentos

Lección 01 — Visión y tipos de Cloud Load Balancing

En Application Load Balancers (capa 7, HTTP/HTTPS) y Network Load Balancers (capa 4), y cada familia puede ser externa o interna, global o regional; los Network Load Balancers se dividen en proxy (terminan la conexión) y passthrough (reenvían sin terminarla).

El proxy termina la conexión del cliente y abre otra al backend; el passthrough reenvía los paquetes sin terminarla y conserva la IP del cliente.

Lección 02 — Componentes de un balanceador

Una regla de reenvío (IP y puerto de entrada), un proxy de destino (HTTP o HTTPS) que usa un mapa de URL para elegir un servicio de backend, el cual agrupa backends y health checks; los certificados se asocian al proxy HTTPS.

Define la IP y el puerto en los que el balanceador recibe tráfico y lo dirige al proxy de destino.

Lección 03 — Backends: grupos de instancias y NEG

Grupos de instancias (gestionados o no), grupos de puntos finales de red (NEG: zonales, serverless, híbridos, de internet) y, en el balanceador de aplicaciones, buckets de Cloud Storage para contenido estático.

Cuando los backends son contenedores (pods de GKE), servicios serverless como Cloud Run o endpoints fuera de GCP, que no encajan en un grupo de instancias.

Lección 04 — Health checks y firewall

Reglas de firewall que permitan el tráfico de las sondas de Google (rangos como 130.211.0.0/22 y 35.191.0.0/16 en los balanceadores clásicos y globales) hacia los puertos de los backends, además de configurar el protocolo, puerto y ruta correctos.

Que el firewall permita los rangos de sondeo de Google y que el puerto y la ruta del health check coincidan con la aplicación.

Lección 05 — Niveles de red e IP anycast

Una única IP anycast global anunciada desde el borde de Google: el tráfico entra por el punto de presencia más cercano y viaja por la red troncal de Google hasta el backend, lo que reduce latencia; el nivel Estándar usa internet para más tramos y es regional.

Porque los clientes siempre usan la misma IP, así que no hay que cambiar DNS ni esperar a que caduquen cachés al mover tráfico entre regiones.

Módulo 2: Application Load Balancer

Lección 06 — Mapas de URL y enrutado

Con reglas de host (host rules) y comparadores de ruta (path matchers) que asignan cada combinación de dominio y ruta a un servicio de backend o bucket, con un servicio por defecto para lo que no coincide.

Un path matcher que envía /static/* a un backend bucket de Cloud Storage y deja el resto al servicio de backend por defecto de la API.

Lección 07 — Gestión avanzada del tráfico

Reparto ponderado de tráfico entre servicios (canary), enrutado por cabeceras o parámetros, reescrituras de URL y cabeceras, redirecciones, espejo de tráfico (mirroring), reintentos, timeouts y inyección de fallos para pruebas.

Con un reparto ponderado entre dos servicios de backend (95 % y 5 %) en la regla de ruta.

Lección 08 — Modos de balanceo y capacidad

El criterio con el que se mide su carga para repartir tráfico: UTILIZATION (uso de CPU), RATE (peticiones por segundo) o CONNECTION (conexiones), junto con una capacidad máxima y un capacity scaler que ajusta la parte de tráfico que recibe.

Para reducir o ajustar la proporción de tráfico que recibe un backend, por ejemplo para drenarlo o dar menos carga a una región.

Lección 09 — Sesiones persistentes, timeouts y drenaje

La afinidad de sesión (por IP de cliente, cookie generada o cabecera), el timeout del servicio de backend (30 segundos por defecto en muchos balanceadores) y el drenaje de conexiones, que da tiempo a terminar las existentes al retirar un backend.

El timeout del servicio de backend, aumentándolo para las peticiones largas (o usando otra estrategia para tareas largas).

Lección 10 — Cloud CDN

Se habilita en el servicio de backend o bucket de un balanceador de aplicaciones externo para cachear contenido en el borde de Google, con políticas de caché y claves personalizables, lo que reduce latencia y carga en el origen.

El contenido personalizado, privado o dependiente de sesión, para no servir datos de un usuario a otro.

Módulo 3: Network LB y backends

Lección 11 — Network Load Balancers: proxy y passthrough

Balanceo de capa 4 para TCP con terminación en el proxy (incluida la terminación SSL/TLS en el proxy SSL), con opción global y regional, útil para protocolos que no son HTTP; el cliente conecta con el proxy y este abre otra conexión al backend.

Para tráfico TCP cifrado que no es HTTP, cuando quieres terminar TLS en el balanceador y descargar a los backends.

Lección 12 — Passthrough y preservación de la IP del cliente

Reenvía los paquetes a los backends sin terminar la conexión, conserva la IP de origen del cliente, admite TCP, UDP y otros protocolos IP, y la respuesta vuelve directamente al cliente (retorno directo del servidor) sin pasar por el balanceador.

Permite aplicar reglas y registrar por IP real del cliente sin cabeceras adicionales.

Lección 13 — Balanceador interno y subred solo proxy

Una subred solo para proxies (proxy-only subnet) en la región y la red, de donde los proxies gestionados por Google usan sus direcciones para conectar con los backends, por lo que los firewalls deben permitir ese rango hacia ellos.

Que el firewall permita el tráfico desde el rango de la proxy-only subnet hacia el puerto de los backends.

Lección 14 — NEG: serverless y contenedores en GKE

Un NEG serverless apunta a un servicio de Cloud Run, App Engine o Cloud Functions para ponerlos detrás de un balanceador (con CDN, Cloud Armor y dominio propio), y los NEG zonales permiten balanceo nativo de contenedores que envía tráfico directamente a los pods de GKE.

Menos saltos de red y menor latencia, y health checks por pod en lugar de por nodo.

Lección 15 — Multirregión, NEG híbridos y conmutación

Con un balanceador global y backends en varias regiones: el tráfico va a la región sana más cercana según la capacidad, con conmutación automática si falla; los NEG híbridos o de internet permiten incluir backends fuera de GCP.

Capacidad suficiente para absorber el tráfico de la región que falla; si no, la conmutación causaría sobrecarga.

Módulo 4: Seguridad y operación

Lección 16 — TLS y certificados gestionados

El proxy HTTPS termina TLS con certificados autogestionados o gestionados por Google (que se renuevan solos tras validar el dominio), con varios certificados por proxy y una política SSL que fija la versión mínima y los cifrados; redirigir HTTP a HTTPS se hace con un mapa de URL.

Porque requiere validar el dominio, y el DNS debe apuntar ya a la IP del balanceador.

Lección 17 — Cloud Armor

Protección DDoS y WAF para balanceadores externos con políticas de seguridad: reglas por IP, geografía, firmas de ataques web, limitación de tasa y reglas preconfiguradas, aplicadas en el borde antes de llegar al backend.

Con una regla de limitación de tasa o un bloqueo por IP en la política de Cloud Armor.

Lección 18 — Identity-Aware Proxy y control de acceso

Para exigir autenticación y autorización a nivel de aplicación mediante identidades de Google, delante de un balanceador de aplicaciones, sin necesidad de VPN: solo acceden los usuarios con el rol adecuado.

Controla el acceso por identidad y por aplicación, sin exponer la red completa con una VPN.

Lección 19 — Observabilidad y troubleshooting

Con los registros del balanceador en Cloud Logging, que indican el motivo del fallo (por ejemplo backend no disponible o timeout), con métricas en Cloud Monitoring y comprobando health checks, firewall, capacidad y el timeout del servicio de backend.

Backends no sanos, aumento de errores 5xx o latencia elevada.

Lección 20 — Proyecto final: balanceo listo para producción

Balanceador de aplicaciones externo global con IP anycast, certificados gestionados y política SSL moderna, backends en varias regiones con capacidad de conmutación, Cloud Armor, health checks y firewall correctos, Cloud CDN donde aplique, monitorización con alertas y todo como código.

Backends en varias regiones, Cloud Armor y monitorización con alertas (más TLS gestionado y health checks).