

// Jivops

Google Cloud Run

Guía completa — 20 lecciones

Fundamentos · Red y escalado · Seguridad e integración · Operación

Contenido

Módulo 1: Fundamentos

- Lección 01 — Qué es Cloud Run
- Lección 02 — Servicios y revisiones
- Lección 03 — Requisitos del contenedor
- Lección 04 — Despliegue de imágenes y código fuente
- Lección 05 — Servicios frente a jobs

Módulo 2: Escalado, red y tráfico

- Lección 06 — Escalado y concurrencia
- Lección 07 — Ingress y control de acceso
- Lección 08 — Conectividad a VPC
- Lección 09 — División de tráfico y etiquetas
- Lección 10 — Dominios y balanceador

Módulo 3: Seguridad e integración

- Lección 11 — Cuentas de servicio
- Lección 12 — Secret Manager
- Lección 13 — Bases de datos y almacenamiento
- Lección 14 — Eventos y mensajería
- Lección 15 — Cloud Run jobs

Módulo 4: Operación y costes

- Lección 16 — Observabilidad
- Lección 17 — Infraestructura como código
- Lección 18 — Costes y facturación
- Lección 19 — Resolución de problemas
- Lección 20 — Proyecto final: API de producción en Cloud Run

Módulo 1: Fundamentos

Lección 01 — Qué es Cloud Run

Una plataforma serverless de Google Cloud para ejecutar contenedores sin estado que responden a peticiones HTTP o a eventos, o que se ejecutan como trabajos, con escalado automático (incluido a cero) y facturación por uso, sin gestionar servidores ni clústeres.

No gestionas el clúster, escala a cero y pagas por uso, con un despliegue muy simple.

Lección 02 — Servicios y revisiones

El servicio es el recurso con un nombre y una URL estable que recibe peticiones; cada despliegue o cambio de configuración crea una revisión inmutable, y el servicio dirige el tráfico a una o varias revisiones.

Permiten volver a una versión anterior con trazabilidad y despliegues reproducibles.

Lección 03 — Requisitos del contenedor

Debe escuchar peticiones en el puerto indicado en la variable de entorno PORT, ser sin estado, arrancar rápido y tratar el sistema de archivos local como efímero; cualquier lenguaje o framework vale si se empaqueta en una imagen.

Porque reduce el arranque en frío y la latencia de la primera petición al escalar.

Lección 04 — Despliegue de imágenes y código fuente

Desplegando una imagen guardada en Artifact Registry o directamente desde código fuente con buildpacks o un Dockerfile mediante Cloud Build, con el comando `gcloud run deploy` o desde un pipeline de integración continua.

Es rápido y simple: los buildpacks construyen la imagen sin necesidad de escribir un Dockerfile.

Lección 05 — Servicios frente a jobs

Un servicio atiende peticiones de forma continua con URL y escala según la demanda; un job ejecuta tareas hasta terminar, con una o varias tareas en paralelo y reintentos, para lotes, migraciones o procesos programados.

Procesos por lotes, migraciones de datos, generación de informes o tareas programadas.

Módulo 2: Escalado, red y tráfico

Lección 06 — Escalado y concurrencia

Añade instancias según las peticiones concurrentes que cada instancia puede atender (concurrencia, 80 por defecto), entre un mínimo y un máximo de instancias configurables, y puede escalar a cero cuando no hay tráfico.

Se evita el arranque en frío y baja la latencia, pero se paga por las instancias inactivas.

Lección 07 — Ingress y control de acceso

Con IAM mediante el rol Invoker (run.invoker): por defecto solo pueden llamar identidades autorizadas con un token; se puede permitir acceso público sin autenticación explícitamente, y el ingress limita el origen (internet, interno o balanceador).

Para un sitio web o API pública sin datos sensibles; los servicios internos deben exigir autenticación.

Lección 08 — Conectividad a VPC

Mediante salida directa a la VPC (Direct VPC egress) o un conector de acceso a VPC sin servidor, que permiten llegar a IP privadas como Cloud SQL, Memorystore o servicios on-premises, y controlar si todo el tráfico sale por la VPC.

Para usar IP privada sin exponer la base de datos a internet, mejorando la seguridad.

Lección 09 — División de tráfico y etiquetas

Desplegando sin enviarle tráfico, probándola con una etiqueta que da una URL propia, y repartiendo después un porcentaje del tráfico entre revisiones hasta el 100 %, con la posibilidad de volver a la anterior en cualquier momento.

Permite validar la revisión sin enviarle usuarios reales, reduciendo el riesgo.

Lección 10 — Dominios y balanceador

Con mapeo de dominio directo o, mejor para producción, con un balanceador de carga HTTP(S) global con NEG sin servidor, que permite certificados gestionados, Cloud CDN, Cloud Armor y varias regiones.

Permite servir desde varias regiones con CDN, WAF y certificados gestionados.

Módulo 3: Seguridad e integración

Lección 11 — Cuentas de servicio

Una cuenta de servicio que el servicio asume al llamar a otras APIs de Google Cloud; conviene crear una dedicada con los roles mínimos en lugar de usar la cuenta por defecto, que suele tener permisos excesivos.

Aísla permisos mínimos y limita el impacto si un servicio se compromete, con mejor auditoría.

Lección 12 — Secret Manager

Guardándolos en Secret Manager y montándolos como variable de entorno o como archivo, con permiso de la cuenta de servicio para leerlos; se pueden versionar y rotar sin reconstruir la imagen.

Permite rotar o volver a una versión anterior sin reconstruir la imagen.

Lección 13 — Bases de datos y almacenamiento

Fuera del contenedor: Cloud SQL (con conexión integrada), Firestore, Spanner, Memorystore o Cloud Storage; también se pueden montar buckets de Cloud Storage o recursos compartidos NFS como volúmenes.

Porque las instancias son efímeras y se crean y destruyen al escalar; guardar datos local los perdería.

Lección 14 — Eventos y mensajería

Con Pub/Sub (suscripciones push), Eventarc (eventos de servicios de Google Cloud), Cloud Tasks (colas con reintentos) y Cloud Scheduler (llamadas periódicas), que invocan el servicio con una identidad autorizada.

Cuando se quiere una cola con control del ritmo y reintentos hacia un destino concreto.

Lección 15 — Cloud Run jobs

Ejecutan un contenedor hasta completar su tarea, con N tareas en paralelo, reintentos y tiempo máximo por tarea; se lanzan manualmente, por Cloud Scheduler o por eventos, y no tienen URL ni atienden peticiones.

Procesamiento por lotes, ETL, migraciones y tareas programadas.

Módulo 4: Operación y costes

Lección 16 — Observabilidad

Los logs de stdout/stderr van a Cloud Logging, las métricas (solicitudes, latencia, instancias, CPU, memoria) a Cloud Monitoring, las trazas a Cloud Trace, y se configuran alertas y objetivos de nivel de servicio.

Errores 5xx, latencia alta y saturación o número de instancias anómalo.

Lección 17 — Infraestructura como código

Con Terraform, con el YAML declarativo del servicio (gcloud run services replace) o con Deployment Manager y herramientas similares; el código se versiona y se despliega desde un pipeline para tener entornos reproducibles.

Permite revisión, historial y entornos idénticos y reproducibles.

Lección 18 — Costes y facturación

Por defecto por uso: la CPU y memoria solo mientras se procesan peticiones, más el número de peticiones; con CPU siempre asignada se paga mientras la instancia existe; las instancias mínimas y la salida de red también cuentan.

Escalar a cero, ajustar CPU y memoria, no fijar instancias mínimas y subir la concurrencia.

Lección 19 — Resolución de problemas

Que el contenedor escuche en el puerto de la variable PORT en todas las interfaces, los logs de arranque, que la memoria sea suficiente, el tiempo de arranque frente a la sonda y los permisos para leer la imagen y los secretos.

Alcanzar el máximo de instancias o la concurrencia, o arranques en frío lentos.

Lección 20 — Proyecto final: API de producción en Cloud Run

Servicio desplegado desde Artifact Registry con cuenta de servicio dedicada, balanceador global con Cloud Armor y dominio propio, ingress restringido, Cloud SQL por IP privada, secretos en Secret Manager, instancias mínimas, concurrencia ajustada, reparto de tráfico entre revisiones, Pub/Sub y jobs para trabajo asíncrono, logs y alertas, e infraestructura como código.

Prueba de carga, alertas, plan de rollback y revisión de permisos mínimos.