

// Jivops

IA en la Nube

Guía completa — 30 lecciones

Panorama general · AWS · Azure · Google Cloud · Arquitectura multi-cloud ·
Producción avanzada

Contenido

Módulo 1: Panorama de IA en la nube

- Lección 01 — Por qué usar servicios de IA gestionados en la nube en vez de construir todo propio
- Lección 02 — Los tres grandes: AWS, Azure, GCP — panorama general de sus ofertas de IA
- Lección 03 — Modelos de servicio: IaaS, PaaS y modelos totalmente gestionados para IA
- Lección 04 — Elegir entre API gestionada vs infraestructura gestionada vs self-hosted
- Lección 05 — Vendor lock-in en IA — riesgos y mitigaciones

Módulo 2: AWS para IA

- Lección 06 — Amazon Bedrock — acceso gestionado a modelos fundacionales
- Lección 07 — Amazon SageMaker — plataforma de ML de extremo a extremo
- Lección 08 — SageMaker endpoints — despliegue de modelos para inferencia
- Lección 09 — AWS y GPUs — instancias EC2 para IA (P4, P5, Inferentia, Trainium)
- Lección 10 — Servicios de IA especializados de AWS (Textract, Transcribe, Rekognition)

Módulo 3: Azure para IA

- Lección 11 — Azure OpenAI Service — acceso gestionado a modelos de OpenAI
- Lección 12 — Azure Machine Learning — plataforma de ML de Microsoft
- Lección 13 — Azure AI Search — búsqueda vectorial e híbrida gestionada
- Lección 14 — Content Safety y guardrails nativos en Azure AI
- Lección 15 — Integración de Azure AI con el ecosistema Microsoft (Copilot, Power Platform)

Módulo 4: Google Cloud para IA

- Lección 16 — Vertex AI — plataforma unificada de ML de Google Cloud
- Lección 17 — Modelos Gemini vía Vertex AI
- Lección 18 — Vertex AI Search y Vertex AI Agent Builder
- Lección 19 — TPUs — el hardware de IA propio de Google
- Lección 20 — Model Garden — catálogo de modelos en Vertex AI

Módulo 5: Arquitectura multi-cloud y decisiones de diseño

- Lección 21 — Comparar el costo real entre proveedores para una misma carga de trabajo de IA
- Lección 22 — Abstracciones multi-cloud — LiteLLM y capas de compatibilidad
- Lección 23 — Latencia y ubicación de datos — elegir la región correcta
- Lección 24 — Bases de datos vectoriales gestionadas en la nube
- Lección 25 — Estrategias de failover entre proveedores de IA

Módulo 6: Producción avanzada

Lección 26 — Seguridad y cumplimiento de IA en la nube (IAM, VPC, cifrado)

Lección 27 — Monitoreo y costos en servicios de IA gestionados

Lección 28 — CI/CD para despliegues de IA en la nube

Lección 29 — Casos de uso — cuándo cada proveedor tiene ventaja real

Lección 30 — Proyecto final: arquitectura de IA en la nube completa lista para producción

Módulo 1: Panorama de IA en la nube

Lección 01 — Por qué usar servicios de IA gestionados en la nube en vez de construir todo propio

Reduce significativamente la carga operativa (gestión de servidores, actualizaciones, escalado, parches de seguridad), permitiendo al equipo enfocarse en construir la aplicación en vez de mantener infraestructura de bajo nivel.

Un equipo pequeño de startup tiene tiempo y recursos limitados; dedicar meses a construir, configurar y mantener infraestructura propia de inferencia retrasaría significativamente el momento en que pueden ofrecer valor real a sus usuarios, mientras un servicio gestionado les permite empezar a integrar esa capacidad de IA de inmediato, enfocando su tiempo limitado en construir el producto en sí.

Lección 02 — Los tres grandes: AWS, Azure, GCP — panorama general de sus ofertas de IA

Los tres ofrecen una combinación de acceso gestionado a modelos fundacionales, plataformas de ML de extremo a extremo para entrenar y desplegar modelos propios, y servicios de IA especializados preentrenados para tareas comunes, aunque con implementaciones y nombres distintos entre sí.

Sin conocer qué ofrece cada proveedor en términos generales, un equipo podría quedarse atado a la primera opción que investigó sin saber si otro proveedor ofrece algo mejor ajustado a su necesidad específica (mejor precio, mejor modelo disponible, mejor integración); tener ese panorama comparativo general permite tomar una decisión más informada entre las opciones reales disponibles en el mercado.

Lección 03 — Modelos de servicio: IaaS, PaaS y modelos totalmente gestionados para IA

Con IaaS el usuario gestiona prácticamente todo (sistema operativo, drivers, framework), con PaaS el proveedor gestiona más infraestructura dejando al usuario enfocarse en el modelo y los datos, y con una API totalmente gestionada el usuario solo envía peticiones sin gestionar nada de la infraestructura subyacente.

Configurar y mantener correctamente instancias con GPU en bruto (drivers, frameworks, optimización) requiere conocimiento técnico específico que ese equipo sin experiencia previa probablemente no tiene todavía; una API totalmente gestionada abstrae por completo esa complejidad técnica, permitiendo al equipo enfocarse directamente en integrar la capacidad de IA en su aplicación sin esa curva de aprendizaje adicional.

Lección 04 — Elegir entre API gestionada vs infraestructura gestionada vs self-hosted

La necesidad real de control sobre dónde viven los datos (por requisitos de privacidad o regulación) y sobre el comportamiento específico del modelo, ponderada contra el valor de la simplicidad operativa que ofrece una API gestionada.

Si la regulación exige control directo y verificable sobre exactamente dónde residen los datos sensibles en todo momento, enviar esos datos hacia la API externa de un proveedor gestionado (donde el control es menos directo) podría no cumplir ese requisito; en ese contexto específico, el valor de cumplir la regulación pesaría más que la conveniencia operativa que ofrecería una API gestionada más simple de usar.

Lección 05 — Vendor lock-in en IA — riesgos y mitigaciones

Cambiar de proveedor en el futuro (por mejor precio, mejor modelo, o cualquier otra razón) se vuelve costoso y complejo, ya que requeriría reescribir partes significativas de la integración diseñada específicamente para las particularidades de ese proveedor original.

Si la integración aprovecha características muy específicas y únicas de la API de un proveedor particular (que no tienen un equivalente exacto en otros proveedores), migrar hacia otro proveedor después requeriría reescribir esas partes específicas del código; una organización que usó desde el inicio una capa de abstracción más genérica (que no depende de esas particularidades únicas) podría cambiar el proveedor subyacente con mucho menos esfuerzo de reescritura.

Módulo 2: AWS para IA

Lección 06 — Amazon Bedrock — acceso gestionado a modelos fundacionales

Acceso gestionado, a través de una API unificada, a múltiples modelos fundacionales de distintos proveedores (como Anthropic, Meta, entre otros), sin necesitar gestionar la infraestructura de inferencia subyacente para cada uno.

Como Bedrock unifica el formato de las peticiones hacia distintos modelos bajo la misma interfaz, cambiar de un modelo de un proveedor a otro (por ejemplo, para comparar calidad o costo) requiere ajustes mucho más pequeños en el código, en vez de tener que reescribir completamente la integración como sería necesario si cada proveedor tuviera un formato de API completamente distinto e independiente.

Lección 07 — Amazon SageMaker — plataforma de ML de extremo a extremo

SageMaker cubre el ciclo de vida completo de ML (preparación de datos, entrenamiento de modelos propios, ajuste de hiperparámetros, despliegue, monitoreo), mientras Bedrock se enfoca específicamente en dar acceso a modelos fundacionales ya entrenados listos para usar.

Bedrock da acceso a modelos fundacionales ya entrenados y listos para usar, pero no está diseñado para entrenar un modelo completamente nuevo desde cero con datos propios específicos de negocio; SageMaker sí cubre específicamente ese proceso de entrenamiento personalizado, siendo la herramienta apropiada cuando el objetivo es construir un modelo propio en vez de usar uno ya existente.

Lección 08 — SageMaker endpoints — despliegue de modelos para inferencia

Provisiona la infraestructura de cómputo necesaria, expone una API HTTP para recibir peticiones de inferencia, y gestiona aspectos operativos como el escalado según la demanda, sin que el usuario tenga que configurar manualmente servidores individuales.

Con tráfico variable e impredecible, ajustar manualmente el número de servidores cada vez que cambia la demanda sería un esfuerzo operativo continuo y reactivo difícil de sostener; un endpoint gestionado que escala automáticamente según la demanda real elimina esa necesidad de intervención manual constante, adaptándose de forma más práctica y eficiente a las variaciones de tráfico sin ese trabajo operativo repetitivo.

Lección 09 — AWS y GPUs — instancias EC2 para IA (P4, P5, Inferentia, Trainium)

Las instancias con GPU NVIDIA usan hardware de un fabricante externo ampliamente compatible con el ecosistema de ML existente, mientras Inferentia y Trainium son chips diseñados específicamente por AWS, optimizados para inferencia y entrenamiento respectivamente, potencialmente con mejor costo-eficiencia para ciertas cargas específicas.

Un chip diseñado específicamente para optimizar el proceso de inferencia (como Inferentia) puede ofrecer una mejor eficiencia de costo por esa tarea específica, comparado con una GPU de propósito más general diseñada para manejar una variedad más amplia de cargas distintas; para un volumen alto y estable de inferencia, esa especialización específica del chip puede traducirse en un ahorro real de costo operativo.

Lección 10 — Servicios de IA especializados de AWS (Textract, Transcribe, Rekognition)

Resuelven tareas específicas y bien definidas (extracción de texto de documentos, transcripción de audio a texto, reconocimiento de objetos en imágenes) mediante APIs optimizadas específicamente para ese propósito, a menudo con mejor precisión y menor esfuerzo de integración que adaptar un modelo genérico para esa misma tarea.

Textract fue diseñado y optimizado específicamente para la tarea de extraer texto de documentos con distintos formatos y estructuras, mientras adaptar un modelo de propósito general para lograr un resultado igualmente preciso en esa misma tarea específica requeriría trabajo adicional de ajuste y validación; usar el servicio ya especializado ahorra ese esfuerzo, aprovechando una solución ya optimizada específicamente para ese caso.

Módulo 3: Azure para IA

Lección 11 — Azure OpenAI Service — acceso gestionado a modelos de OpenAI

Da acceso a los mismos modelos de OpenAI pero dentro de la infraestructura y garantías de cumplimiento empresarial de Azure (como controles de red privada, SLA empresariales, e integración con el ecosistema de identidad y seguridad de Microsoft).

Una empresa grande que ya opera dentro del ecosistema de Microsoft (Active Directory, redes privadas configuradas, cumplimiento normativo ya establecido en Azure) puede aprovechar directamente esa infraestructura de seguridad y cumplimiento existente al usar Azure OpenAI Service, en vez de tener que gestionar por separado una integración completamente independiente con la API directa de OpenAI que no tendría esas mismas garantías empresariales ya integradas.

Lección 12 — Azure Machine Learning — plataforma de ML de Microsoft

Cubre el ciclo de vida completo de machine learning (preparación de datos, entrenamiento de modelos propios, experimentación, despliegue y monitoreo), permitiendo a un equipo construir y operar sus propios modelos personalizados dentro de la infraestructura de Azure.

Azure OpenAI Service da acceso a modelos generales ya entrenados por OpenAI, pero no está diseñado para entrenar un modelo completamente nuevo con datos propios específicos de una industria particular; Azure Machine Learning sí cubre específicamente ese proceso de entrenamiento personalizado, siendo la herramienta apropiada cuando el objetivo es construir un modelo propio ajustado a un caso muy específico, no usar uno genérico ya existente.

Lección 13 — Azure AI Search — búsqueda vectorial e híbrida gestionada

Soporta búsqueda vectorial semántica y búsqueda híbrida (combinando vectorial con búsqueda léxica tradicional) de forma completamente gestionada, sin que el usuario tenga que configurar y operar su propia infraestructura de base de datos vectorial por separado.

Si el resto de la aplicación ya está construida dentro del ecosistema de Azure, usar Azure AI Search gestionado evita tener que desplegar, configurar y mantener una base de datos vectorial completamente separada como pieza adicional de infraestructura; la integración nativa con el resto de servicios de Azure ya en uso simplifica el flujo completo de construir el sistema RAG sin esa complejidad operativa extra.

Lección 14 — Content Safety y guardrails nativos en Azure AI

Analiza tanto las entradas de los usuarios como las respuestas generadas por el modelo en busca de contenido potencialmente dañino (violento, de odio, sexual, entre otras categorías), actuando como un guardrail nativo integrado directamente dentro del ecosistema de Azure.

Construir un sistema propio de detección de contenido dañino desde cero requeriría tiempo de desarrollo, entrenamiento de un clasificador específico y mantenimiento continuo; tener ese guardrail ya integrado y probado nativamente dentro del mismo ecosistema de Azure donde ya vive la aplicación permite obtener esa capa de protección de forma mucho más rápida y sencilla, sin ese esfuerzo de desarrollo adicional propio.

Lección 15 — Integración de Azure AI con el ecosistema Microsoft (Copilot, Power Platform)

Permite construir soluciones de IA que se conectan directamente con las herramientas de productividad y desarrollo que los empleados ya usan diariamente (como Office, Teams, aplicaciones de Power Platform), reduciendo la fricción de adopción al no requerir aprender un sistema completamente nuevo y separado.

Los empleados ya saben cómo usar Office y Teams sin ninguna curva de aprendizaje adicional; si la capacidad de IA aparece integrada directamente dentro de esas mismas herramientas familiares, la adopción es mucho más natural y rápida que si tuvieran que aprender a usar una aplicación de IA completamente separada y nueva, con su propia interfaz distinta que requeriría tiempo adicional de aprendizaje y cambio de hábito.

Módulo 4: Google Cloud para IA

Lección 16 — Vertex AI — plataforma unificada de ML de Google Cloud

Consolida en un mismo lugar el acceso a modelos fundacionales, herramientas de entrenamiento de modelos propios, despliegue, monitoreo y otras capacidades de ML, evitando que el usuario tenga que navegar entre múltiples servicios desconectados entre sí para cubrir todo el flujo de trabajo.

Si esas capacidades estuvieran repartidas entre varios servicios separados y desconectados entre sí, el equipo tendría que aprender y gestionar la integración entre cada uno, además de cambiar constantemente de contexto durante el mismo proyecto; tenerlas todas consolidadas dentro de la misma plataforma unificada simplifica significativamente ese flujo de trabajo diario, sin esa fricción adicional de moverse entre sistemas distintos.

Lección 17 — Modelos Gemini vía Vertex AI

Vertex AI es el canal principal a través del cual los desarrolladores de aplicaciones empresariales acceden de forma gestionada a los modelos Gemini, con las garantías de infraestructura, seguridad y escalado propias de Google Cloud.

Una aplicación empresarial en producción necesita garantías reales sobre disponibilidad, seguridad y capacidad de escalar ante demanda variable; acceder a los modelos Gemini a través de Vertex AI aporta precisamente esas garantías propias de la infraestructura robusta de Google Cloud, algo que una vía de acceso menos gestionada y con menos garantías formales no podría ofrecer con el mismo nivel de confiabilidad para ese contexto empresarial crítico.

Lección 18 — Vertex AI Search y Vertex AI Agent Builder

Vertex AI Search provee capacidades gestionadas de búsqueda semántica e híbrida para construir sistemas RAG, mientras Agent Builder facilita construir agentes de IA con acceso a herramientas y flujos conversacionales, ambos sin requerir construir esa infraestructura desde cero.

Construir toda la lógica de un agente (gestión de herramientas, flujo conversacional, coordinación) desde cero con un framework genérico requeriría tiempo de desarrollo adicional y conectar manualmente varias piezas de infraestructura; Agent Builder ya resuelve esos patrones comunes de forma integrada dentro del mismo ecosistema de Google Cloud donde el equipo ya trabaja, acelerando significativamente ese desarrollo sin empezar desde cero.

Lección 19 — TPUs — el hardware de IA propio de Google

Son chips de silicio diseñados específicamente por Google para acelerar operaciones de machine learning (especialmente entrenamiento a gran escala), una alternativa propia al uso de GPUs de terceros como las de NVIDIA, optimizada específicamente para ese propósito dentro del ecosistema de Google Cloud.

Si las TPUs, diseñadas específicamente por Google para acelerar el entrenamiento de modelos de ML a gran escala, ofrecen una mejor relación de costo y rendimiento para ese tipo particular de carga de trabajo dentro de su propio ecosistema de Google Cloud, un equipo enfocado en maximizar la eficiencia de su presupuesto de entrenamiento tendría una razón práctica real para elegir esa opción en vez de una GPU NVIDIA de propósito más general.

Lección 20 — Model Garden — catálogo de modelos en Vertex AI

Ofrece un catálogo centralizado y navegable de modelos disponibles (tanto propios de Google como de terceros, incluidos algunos modelos open-source), permitiendo comparar y elegir el modelo más apropiado según el caso de uso específico sin buscar esa información dispersa en múltiples lugares distintos.

Sin un catálogo centralizado, el desarrollador tendría que buscar información sobre cada modelo disponible en fuentes separadas y dispersas, comparando manualmente características y precios entre pestañas distintas; tener todas esas opciones organizadas juntas dentro de Model Garden facilita una comparación mucho más rápida y directa, ahorrando ese tiempo de investigación dispersa antes de tomar una decisión informada.

Módulo 5: Arquitectura multi-cloud y decisiones de diseño

Lección 21 — Comparar el costo real entre proveedores para una misma carga de trabajo de IA

El costo real depende también de factores como la eficiencia específica del modelo para esa tarea, costos adicionales de transferencia de datos o almacenamiento, y el volumen real de uso, que pueden variar significativamente el costo total final más allá del precio base publicado.

Aunque el precio por token sea idéntico entre ambos proveedores, si el modelo de uno necesita generar respuestas notablemente más largas (más tokens) para lograr el mismo resultado útil que el modelo del otro proveedor, el costo total acumulado sería mayor para ese primer proveedor, a pesar de tener el mismo precio nominal por unidad; una comparación justa de costo real necesita considerar la eficiencia práctica de cada modelo, no solo el precio publicado por token.

Lección 22 — Abstracciones multi-cloud — LiteLLM y capas de compatibilidad

Provee una interfaz de programación unificada que traduce hacia el formato específico de cada proveedor por detrás, permitiendo al desarrollador escribir código una sola vez y cambiar de proveedor (o combinar varios) sin reescribir la lógica de integración para cada uno por separado.

Si la aplicación está integrada directamente contra las particularidades específicas de la API de un único proveedor, cambiar después requeriría reescribir esa lógica de integración desde cero; con una capa de abstracción como LiteLLM, el código de la aplicación permanece independiente de esos detalles específicos, así que cambiar de proveedor (o combinar varios) requiere solo ajustar la configuración, no reescribir la lógica completa de integración, reduciendo directamente ese riesgo de vendor lock-in.

Lección 23 — Latencia y ubicación de datos — elegir la región correcta

Una región más cercana geográficamente a los usuarios reduce la latencia de red de cada petición, mientras que ciertas regulaciones (como las de protección de datos en la Unión Europea) pueden exigir que los datos de usuarios específicos se procesen y almacenen dentro de una región geográfica particular.

Cada petición de red tiene que viajar físicamente desde el usuario hasta el servidor y de vuelta; si el servidor está ubicado en Estados Unidos mientras el usuario real está en Europa, esa distancia física mayor se traduce directamente en más tiempo de viaje de la señal (latencia de red), algo que se evitaría desplegando el servicio en una región geográficamente más cercana a donde realmente están los usuarios.

Lección 24 — Bases de datos vectoriales gestionadas en la nube

Reduce la carga operativa de gestionar el escalado, la disponibilidad y el mantenimiento de la base de datos vectorial, dejando esa responsabilidad al proveedor, mientras el equipo se enfoca en construir la aplicación que la usa.

Un equipo pequeño con recursos limitados de tiempo y personal probablemente preferiría no tener que instalar, configurar y mantener continuamente una solución open source separada por su cuenta; aprovechar la oferta gestionada del mismo proveedor cloud que ya usan simplifica la arquitectura general, dejando esa responsabilidad operativa en manos del proveedor mientras el equipo dedica su tiempo limitado a construir el producto real.

Lección 25 — Estrategias de failover entre proveedores de IA

Mantiene la disponibilidad del servicio para los usuarios finales incluso si el proveedor de IA principal tiene una caída temporal, redirigiendo automáticamente las peticiones hacia un proveedor alternativo configurado como respaldo, en vez de que toda la aplicación quede completamente inaccesible.

Si la aplicación depende completamente y de forma exclusiva de un único proveedor de IA sin ningún mecanismo de respaldo configurado, ese proveedor se convierte en un punto único de fallo para toda la aplicación; cuando ese proveedor específico experimenta una interrupción, no existe ninguna alternativa automática hacia la cual redirigir el tráfico, dejando a la aplicación completa inaccesible hasta que ese proveedor específico se recupere por su cuenta.

Módulo 6: Producción avanzada

Lección 26 — Seguridad y cumplimiento de IA en la nube (IAM, VPC, cifrado)

Políticas de IAM (gestión de identidad y acceso) que limiten quién puede invocar el servicio de IA, configuración de VPC (red privada) que restrinja el acceso de red, y cifrado tanto en tránsito como en reposo para proteger los datos procesados.

Confiar únicamente en que nadie no autorizado intente acceder, sin ningún control técnico real que lo impida, deja la puerta abierta a un acceso accidental o deliberado por parte de alguien que técnicamente tiene acceso general a la infraestructura pero no debería poder invocar ese servicio específico que procesa datos sensibles; una política de IAM bien configurada actúa como una barrera técnica real y verificable, en vez de depender únicamente de la buena voluntad o el cuidado informal de las personas involucradas.

Lección 27 — Monitoreo y costos en servicios de IA gestionados

El costo de muchos servicios de IA gestionados es variable y depende directamente del volumen de uso real (tokens procesados, llamadas realizadas), lo que significa que un pico inesperado de tráfico o un uso ineficiente puede generar un costo significativamente mayor al esperado, sin el mismo techo predecible de un costo fijo.

Con un servidor tradicional de costo fijo, el gasto mensual permanece igual sin importar cuánto tráfico reciba (dentro de su capacidad); con un servicio de precio variable por token, cada petición adicional generada por ese pico inesperado de tráfico se suma directamente al costo total acumulado, sin ese mismo techo predecible, pudiendo resultar en una factura significativamente más alta de lo anticipado si el volumen real terminó siendo mucho mayor al esperado.

Lección 28 — CI/CD para despliegues de IA en la nube

Incluir pasos de validación de calidad específicos de IA (como evaluación automatizada de un golden set) además de las pruebas tradicionales de código, para detectar si un cambio de prompt o configuración degrada la calidad de las respuestas antes de desplegarlo a producción.

Las pruebas tradicionales de código verifican que el código compile correctamente y pase pruebas unitarias sobre su lógica, pero un cambio de prompt sigue siendo técnicamente código válido aunque produzca respuestas de peor calidad; sin un paso específico de validación de calidad de IA (como evaluar contra un golden set), ese pipeline tradicional no tendría forma de detectar esa degradación específica de calidad antes de que llegue a producción.

Lección 29 — Casos de uso — cuándo cada proveedor tiene ventaja real

Evaluar las necesidades específicas del caso de uso (modelo particular necesario, integración con infraestructura ya existente, requisitos de cumplimiento, presupuesto disponible) y comparar cómo cada proveedor se ajusta a esos criterios particulares, en vez de asumir una superioridad universal de un único proveedor.

La organización ya integrada en el ecosistema Microsoft se beneficiaría de las conexiones nativas que Azure AI ofrece con herramientas que ya usan diariamente, mientras la organización que específicamente necesita los modelos Gemini encontraría sentido natural en usar Google Cloud, que es el canal principal de acceso gestionado a esos modelos; en ambos casos, la decisión más sensata depende del contexto y necesidades específicas de cada organización particular, no de una respuesta universal válida para cualquier situación.

Lección 30 — Proyecto final: arquitectura de IA en la nube completa lista para producción

Elección informada de proveedor(es) según necesidades reales + seguridad con IAM/VPC/cifrado + monitoreo de costos con alertas + estrategia de failover entre proveedores + CI/CD con validación de calidad de IA + arquitectura que minimiza vendor lock-in innecesario.

Intenta mencionar al menos dos pilares: elección informada de proveedor según necesidades reales, seguridad con IAM/VPC/cifrado, monitoreo de costos con alertas o estrategia de failover entre proveedores.